Informe TP4

Tecnología Digital 6

O'Farrell, Rotondaro, González Lobo

INTRODUCCIÓN

El objetivo de este trabajo fue desarrollar, mediante redes neuronales, un modelo capaz de obtener una representación comprimida de las canciones en un espacio latente. Para ello, convertimos las canciones en espectrogramas, lo cual resulta muy ventajoso para aplicar técnicas de aprendizaje profundo. Al ser los autoencoders especialmente efectivos en el reconocimiento de patrones en imágenes, la conversión de audio a una representación visual nos permitió aprovechar al máximo su capacidad para captar características acústicas complejas. Construimos el autoencoder con un encoder, que comprime la información en un vector latente, y un decoder, que la reconstruye, experimentando con diferentes tamaños de vector para identificar el más pequeño que mantuviera una calidad aceptable.

Tras entrenar el autoencoder, realizamos un análisis exploratorio del espacio latente con técnicas como PCA, t-SNE y clustering para visualizar cómo se agrupan las canciones y determinar la capacidad del modelo para identificar géneros musicales. Además, evaluamos la calidad de los audios reconstruidos con métricas cuantitativas y cualitativas. Finalmente, exploramos cómo modificar vectores latentes para generar nuevas canciones, mostrando el potencial creativo de este enfoque.

ENCODEAR LA CANCIÓN EN UN VECTOR LATENTE

En este ejercicio, el objetivo fue construir un autoencoder capaz de comprimir canciones en un vector latente de menor dimensión, permitiendo luego su reconstrucción manteniendo la calidad del audio original. Para ello, diseñamos un autoencoder convolucional compuesto por un encoder que utiliza tres capas de convolución con funciones de activación ReLU para reducir progresivamente la dimensionalidad de los datos, seguido por un decoder que utiliza capas de convolución transpuesta para reconstruir los datos a partir del vector latente. Realizamos experimentos variando el tamaño del vector latente (latent_dim) (128, 64, 32, 16

y 8) para identificar el menor tamaño posible que aún mantuviera una buena calidad de reconstrucción, evaluada a través de la pérdida de validación.

Los resultados muestran que un tamaño de vector latente de 32 es el valor más pequeño que permite obtener reconstrucciones satisfactorias sin perder demasiada calidad. A partir de este punto, reducir aún más el tamaño del vector (latent_dim de 16 y 8) provocó un incremento significativo en la pérdida de validación, lo cual indica una disminución en la calidad de la reconstrucción. Tener un vector latente pequeño es importante porque permite reducir el espacio de almacenamiento y acelerar el procesamiento. Sin embargo, debe mantenerse un equilibrio para no perder información esencial y asegurar que las canciones reconstruidas conserven sus características originales.

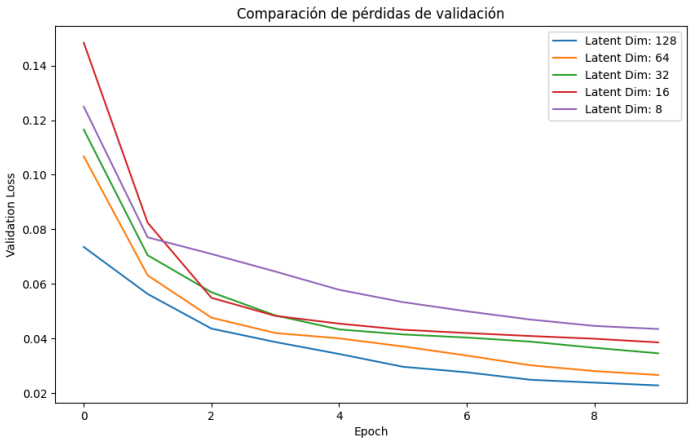

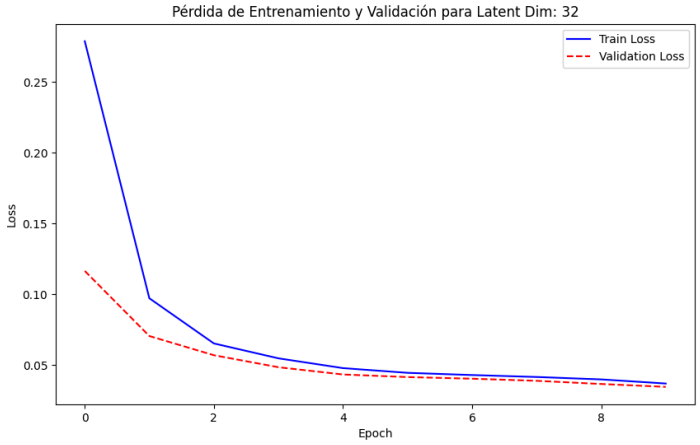

En el primer gráfico, se observa la pérdida de validación para diferentes tamaños de vector latente a lo largo de las épocas de entrenamiento. Los resultados indican que, en general, los modelos con una dimensión latente más grande (como 128 y 64) tienden a tener menores pérdidas en comparación con los tamaños más pequeños (como 16 y 8). Esto se debe a que los vectores latentes más grandes permiten que el modelo capture más información de los datos de entrada, logrando reconstrucciones de mayor calidad.

En el segundo gráfico, se muestra la comparación entre la pérdida de entrenamiento y la pérdida de validación para latent_dim=32. Se observa que ambas pérdidas disminuyen a lo largo de las épocas, lo cual indica que el modelo está aprendiendo a reconstruir los espectrogramas correctamente sin overfittear los datos de entrenamiento. Este tamaño de vector latente proporciona un buen equilibrio entre la reducción del tamaño de los datos y la calidad de la reconstrucción ya que las pérdidas son reducidas.

A continuación observaremos algunas comparaciones entre espectrogramas originales y reconstruidos para observar la pérdida de calidad entre los espectrogramas originales y los reconstruidos en diferentes dimensiones latentes.

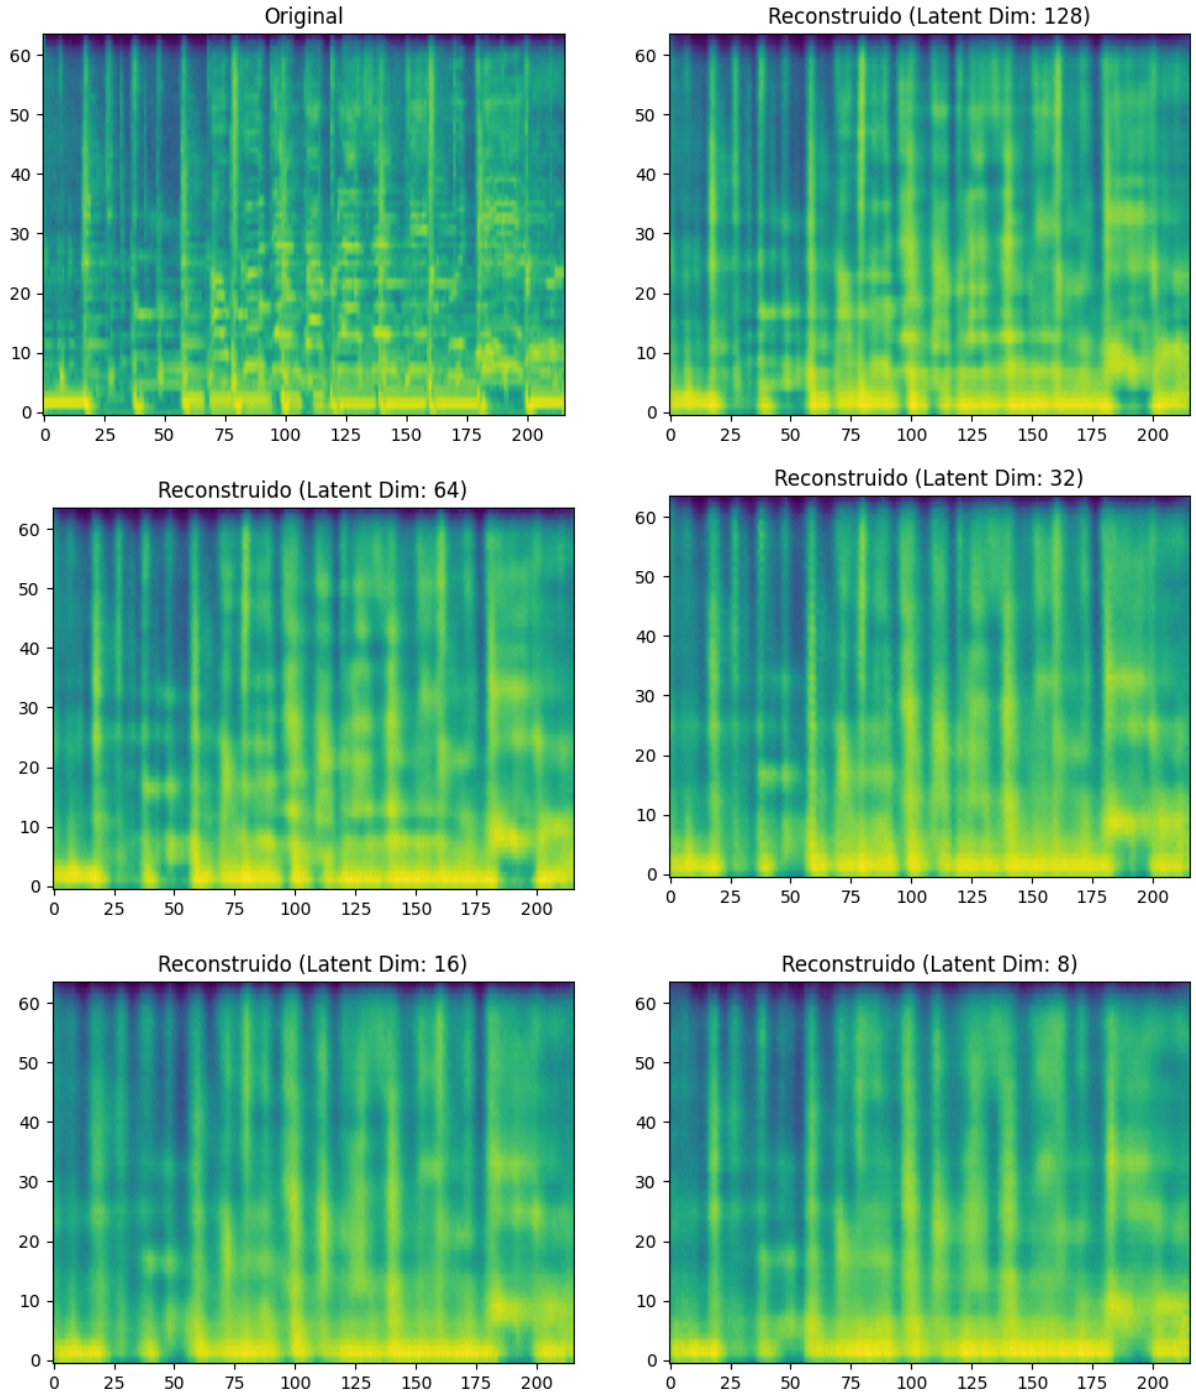

A medida que reducimos la dimensión del vector latente, observamos una pérdida gradual en la calidad de los espectrogramas reconstruidos. Esto se debe a que al disminuir la dimensión del espacio latente, el autoencoder tiene menos capacidad para almacenar toda la información relevante del espectrograma original. Como resultado, solo las características

más generales o significativas son retenidas, mientras que los detalles finos se pierden, lo cual se traduce en una disminución de la calidad y una reconstrucción menos precisa. Esta degradación se evidencia claramente en el ejemplo: los espectrogramas reconstruidos con una dimensión latente mayor (128, 64 o 32) son mucho más parecidos al espectrograma original que los espectrogramas reconstruidos con un autoencoder con dimensión latente menor (16 u 8).

A pesar de nuestros esfuerzos, no logramos reconstruir los audios de manera muy efectiva, principalmente debido a la falta de una técnica que transforme los espectrogramas de vuelta a señales de audio de forma efectiva. La transformación inversa de espectrograma a audio es compleja y está sujeta a pérdidas de calidad, lo cual afecta significativamente el resultado final. Por esta razón, los audios reconstruidos se escuchan distorsionados o de muy baja calidad. Sin embargo, al observar a los espectrogramas reconstruidos y analizar las pérdidas de entrenamiento y validación del modelo, podemos decir que el autoencoder sí está cumpliendo con su objetivo de representar y reconstruir la información esencial del audio de manera adecuada.

ANÁLISIS EXPLORATORIOS DE LOS VECTORES LATENTES

Hacer un análisis exploratorio de los vectores latentes nos ayuda a entender cómo el autoencoder está representando las canciones comprimidas. Básicamente, es una forma de ver si el modelo está capturando patrones importantes, como similitudes entre géneros musicales o características comunes. También nos sirve para comprobar si el autoencoder realmente está reduciendo la cantidad de información sin perder lo esencial, asegurándonos de que los vectores latentes mantienen la estructura necesaria para reconstruir el audio de forma decente.

En nuestro análisis exploratorio de los vectores latentes, primero reducimos la dimensionalidad utilizando PCA y t-SNE para visualizar cómo se agrupan las canciones en el nuevo espacio latente. Esto nos permitió observar si el autoencoder capturaba correctamente las similitudes entre géneros musicales. Luego, realizamos un análisis de clustering usando el método del codo, homogeneidad y completitud para evaluar la calidad de las agrupaciones de los vectores latentes en diferentes cantidades de clusters. La inercia del método del codo mide cuánta varianza queda dentro de los clusters y nos ayuda a

encontrar el número óptimo de clusters. La homogeneidad indica si los elementos de cada cluster comparten la misma clase, mientras que la completitud mide si todos los puntos de la misma clase están en el mismo cluster. Para este análisis, elegimos trabajar con diferentes tamaños de vector latente: 8, 16, 32 y 64. Decidimos que el tamaño más pequeño aceptable era 32, ya que era lo suficientemente pequeño para la compresión sin perder demasiada calidad en la reconstrucción de los audios.

- Con dimensión latente 32x32 estos fueron los resultados:

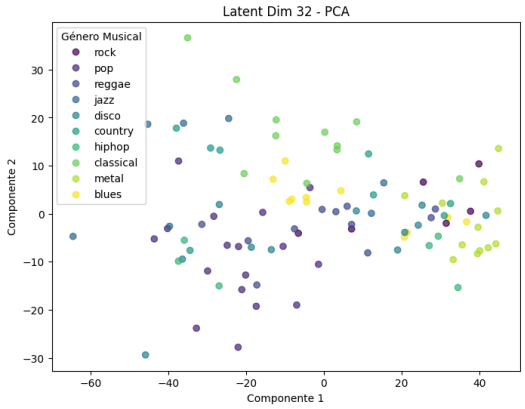

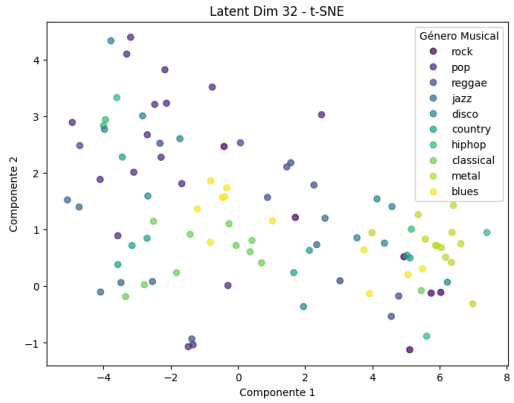

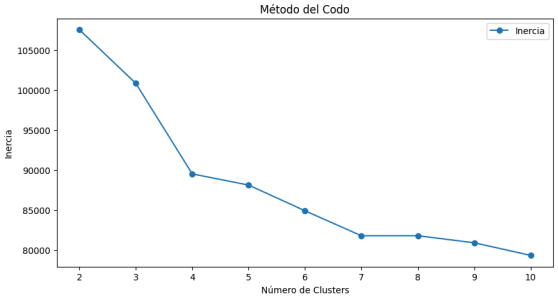

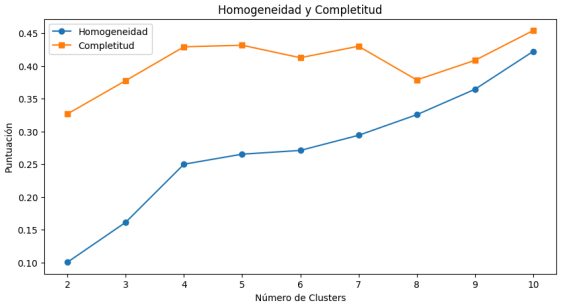

- Con dimensión latente 64x64 estos fueron los resultados:

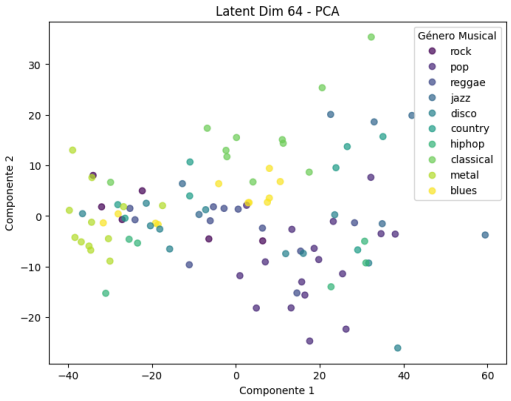

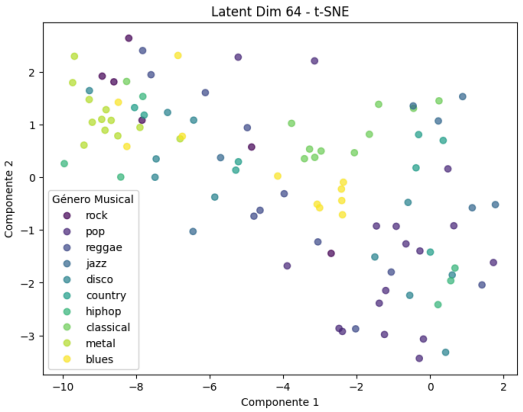

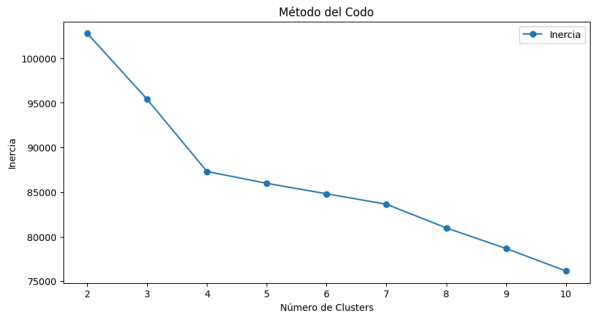

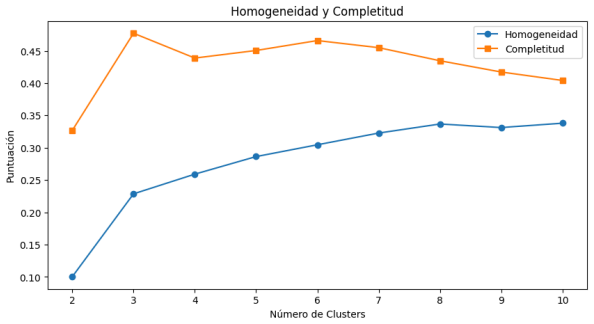

- Con dimensión latente 16x16 estos fueron los resultados:

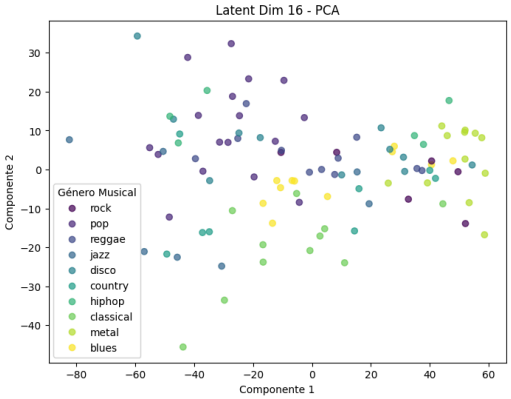

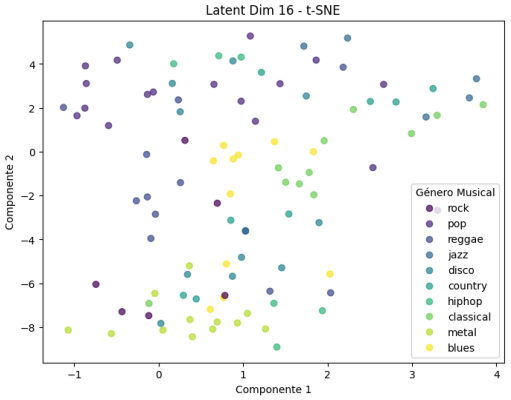

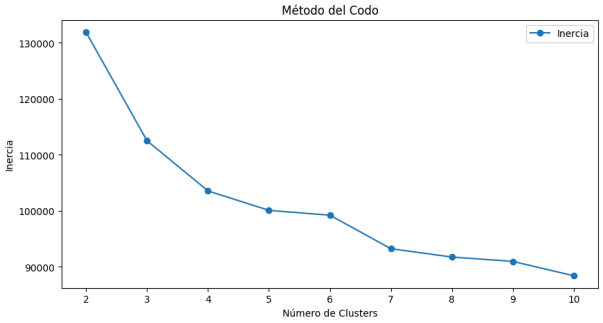

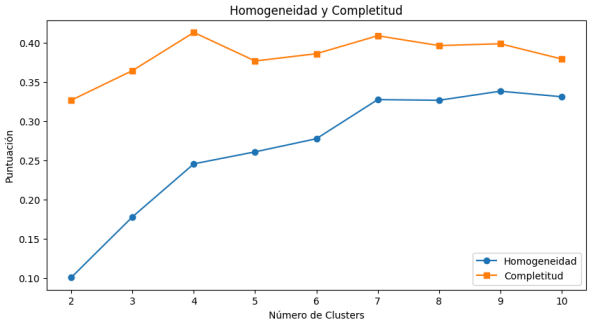

En el análisis de los gráficos de PCA y t-SNE, observamos cómo se distribuyen los vectores latentes en el espacio para cada tamaño del vector latente (latent_dim). Con un tamaño mayor, como latent_dim=64, los géneros musicales tienden a agruparse mejor, lo que nos indica que el autoencoder está siendo más efectivo en captar las características distintivas de cada género. La agrupación más definida muestra que, con una mayor cantidad de dimensiones, el modelo puede representar de manera más rica y precisa las características de las canciones, capturando mejor la complejidad inherente en los distintos géneros.

Por otro lado, cuando usamos una dimensión más pequeña, como latent_dim=16, la dispersión de los puntos en los gráficos es más evidente, lo que indica que el modelo está perdiendo capacidad de representación. Con menos dimensiones disponibles para capturar la información, los vectores latentes tienen menos capacidad para diferenciar entre géneros musicales, lo que lleva a una menor separación y mezcla de géneros en el espacio latente.

Al analizar el método del codo, notamos que la inercia disminuye progresivamente al incrementar el número de clusters. La inercia mide la suma de las distancias al cuadrado de los puntos a sus respectivos centroides; por tanto, una menor inercia significa que los puntos están más cerca de sus centros de cluster. Sin embargo, la reducción de la inercia se vuelve menos pronunciada a partir de cierto punto, indicando que aumentar el número de clusters después de un umbral aporta poco valor adicional. Esto sugiere un posible valor óptimo de k, donde el número de clusters es adecuado para agrupar de forma efectiva los datos sin sobreajustar.

Además, en los gráficos de homogeneidad y completitud, vemos que estas métricas tienden a mejorar ligeramente al incrementar el número de clusters. La homogeneidad mide qué tan similares son los puntos dentro de cada cluster, mientras que la completitud evalúa si todos los puntos del mismo género están en el mismo cluster. Para latent_dim=64, las puntuaciones de homogeneidad y completitud son generalmente mayores que para latent_dim=16, lo que indica que los clusters son más coherentes internamente y que los puntos del mismo género están mejor agrupados. Esto respalda la conclusión de que un mayor tamaño del vector latente permite representar mejor la información y agrupar canciones de manera más precisa según sus géneros.

ENCODEAR MÚSICA NUEVA

Para este ejercicio, buscamos evaluar si nuestro autoencoder, entrenado con canciones del dataset original, es capaz de procesar y comprimir canciones completamente nuevas que no formaban parte del conjunto de entrenamiento. Para ello, tomamos dos canciones externas al dataset — "Jingle Bells" y "Canción Alegre" — y generamos los espectrogramas de estas canciones, luego los encodeamos utilizando nuestro autoencoder con dimensión latente 32

para obtener la representación latente, y reconstruimos el espectrograma a partir de estos vectores latentes.

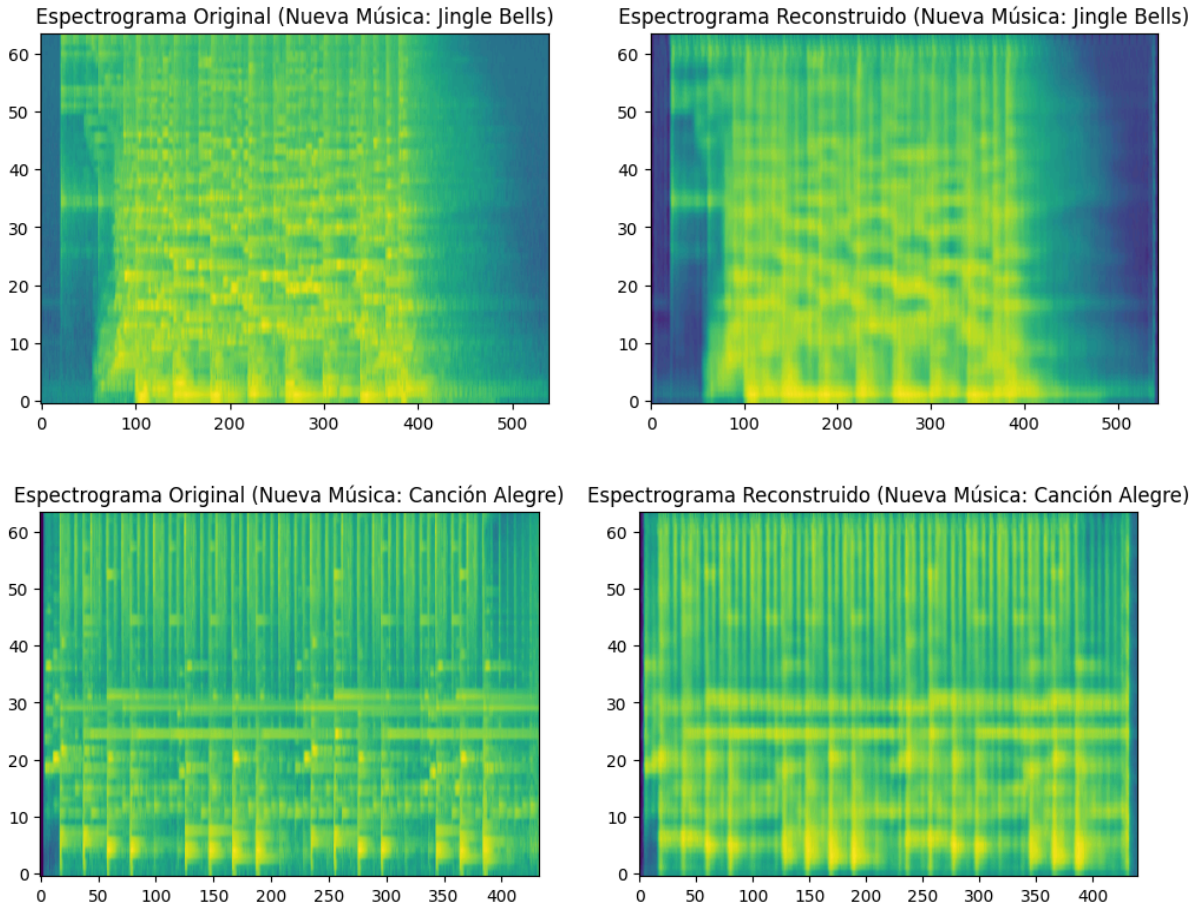

Los resultados, mostrados en los gráficos adjuntos, revelan que los espectrogramas reconstruidos son muy parecidos a los originales, con estructuras y patrones principales bien mantenidos. Sin embargo, se observa cierta pérdida de detalles finos, algo esperable debido a la reducción de dimensionalidad durante la codificación. A pesar de estas pequeñas pérdidas, podemos concluir que el autoencoder funciona bien para canciones nuevas: logra capturar las características principales y reconstruirlas de manera adecuada, demostrando una capacidad de generalización efectiva. Esta habilidad del autoencoder para trabajar con audios externos justifica que, aunque no capture todos los detalles, sí mantiene la esencia de las canciones, lo cual es el objetivo principal de una buena compresión.

GENERACIÓN DE MÚSICA

En este ejercicio, exploramos la posibilidad de generar nuevas canciones modificando los vectores latentes obtenidos del autoencoder. Modificamos los vectores latentes de dos maneras principales: añadiendo ruido aleatorio y realizando interpolaciones con vectores latentes aleatorios. Luego, reconstruimos los espectrogramas para obtener las versiones modificadas de las canciones. Los resultados muestran que estas modificaciones efectivamente alteran los espectrogramas y, consecuentemente, el audio generado, creando variaciones perceptibles del audio original.

Esta técnica demuestra que nuestro método es capaz de generar nuevas variantes musicales a partir de canciones ya existentes. Al añadir ruido, la canción original adquiere un sonido ligeramente distinto, como si hubiera efectos adicionales, mientras que la interpolación crea una versión que combina características del espectrograma original con un componente aleatorio. Esto sugiere que el autoencoder puede no solo comprimir y reconstruir música, sino también permitir modificaciones creativas, haciendo viable la generación de nuevas composiciones basadas en los vectores latentes.

CONCLUSIÓN

En este trabajo, desarrollamos un autoencoder capaz de comprimir canciones a un espacio latente y luego reconstruirlas, logrando un buen equilibrio entre compresión y calidad. Identificamos que un tamaño de vector latente de 32 dimensiones era el menor que aún mantenía una reconstrucción satisfactoria. Al reducir el tamaño del vector a 16 o 8, se observó una clara disminución en la calidad, con una pérdida significativa de detalles, mientras que con tamaños mayores, como 64 y 128, se logró una mayor precisión en la reconstrucción.

El análisis exploratorio de los vectores latentes con PCA, t-SNE y clustering mostró que, con un tamaño latente de 32 o mayor, el autoencoder capturaba similitudes entre géneros musicales, agrupando canciones de manera coherente según sus características. Además, el método del codo y las métricas de homogeneidad y completitud respaldaron que, con mayores dimensiones, se lograba una mejor separación y coherencia de los clusters.

Evaluando la capacidad del autoencoder con canciones nuevas, como "Jingle Bells" y "Canción Alegre", observamos que los espectrogramas reconstruidos eran muy similares a

los originales, aunque con una leve pérdida de detalles. Esto demuestra una buena capacidad de generalización del modelo, siendo capaz de capturar la esencia de las canciones incluso fuera del conjunto de entrenamiento.

Finalmente, al modificar los vectores latentes añadiendo ruido o interpolando, logramos generar nuevas versiones musicales perceptiblemente diferentes. Esto destaca el potencial creativo del autoencoder, permitiendo generar variaciones musicales a partir de un solo vector latente. En resumen, el autoencoder cumplió su objetivo de compresión efectiva y demostró capacidad tanto para reconstruir como para generar música con buena calidad.